

# Inferencia Causal

*Correlación no implica causalidad... ¿o sí?*

Danilo Freire

[danilo.freire@emory.edu](mailto:danilo.freire@emory.edu)

Emory University

¿Por qué importa la  
inferencia causal?



¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

- Empezamos con ustedes: ¿por qué motivos?

# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

- Empezamos con ustedes: ¿por qué motivos?
- Algunas razones:

# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

- Empezamos con ustedes: ¿por qué motivos?
- Algunas razones:
  - Aislar y controlar variables

# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

- Empezamos con ustedes: ¿por qué motivos?
- Algunas razones:
  - Aislar y controlar variables
  - Comparar alternativas

# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

- Empezamos con ustedes: ¿por qué motivos?
- Algunas razones:
  - Aislar y controlar variables
  - Comparar alternativas
  - Facilitar la replicación

# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

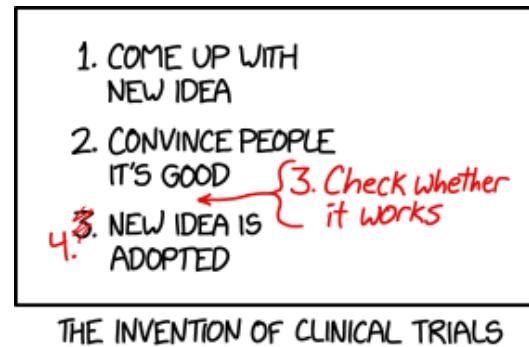
- Empezamos con ustedes: ¿por qué motivos?
- Algunas razones:
  - Aislar y controlar variables
  - Comparar alternativas
  - Facilitar la replicación
  - Mejorar la toma de decisiones

# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

- Empezamos con ustedes: ¿por qué motivos?
- Algunas razones:
  - Aislar y controlar variables
  - Comparar alternativas
  - Facilitar la replicación
  - Mejorar la toma de decisiones
  - Cerrar la brecha entre intención e impacto real de nuestras acciones

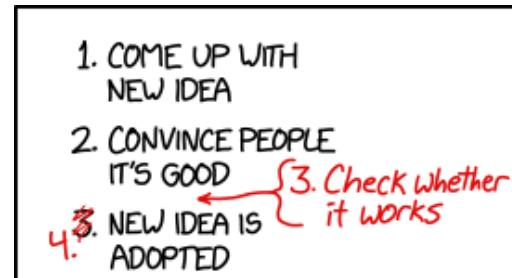
# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

- Empezamos con ustedes: ¿por qué motivos?
- Algunas razones:
  - Aislar y controlar variables
  - Comparar alternativas
  - Facilitar la replicación
  - Mejorar la toma de decisiones
  - Cerrar la brecha entre intención e impacto real de nuestras acciones

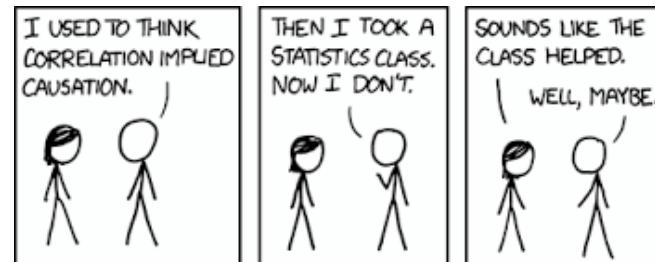


# ¿Por qué a los científicos sociales y los formuladores de políticas les deberían importar la causalidad?

- Empezamos con ustedes: ¿por qué motivos?
- Algunas razones:
  - Aislar y controlar variables
  - Comparar alternativas
  - Facilitar la replicación
  - Mejorar la toma de decisiones
  - Cerrar la brecha entre intención e impacto real de nuestras acciones



THE INVENTION OF CLINICAL TRIALS



# Enfoque Contrafactual de la Inferencia Causal

*Cambios recientes en la investigación en ciencias sociales*

# Enfoque Contrafactual de la Inferencia Causal

*Cambios recientes en la investigación en ciencias sociales*

- Históricamente, la **causalidad inversa** y el **sesgo causado por variables omitidas** han sido problemáticos para muchas investigaciones de las ciencias sociales que buscan hacer afirmaciones causales.

# Enfoque Contrafactual de la Inferencia Causal

## *Cambios recientes en la investigación en ciencias sociales*

- Históricamente, la **causalidad inversa** y el **sesgo causado por variables omitidas** han sido problemáticos para muchas investigaciones de las ciencias sociales que buscan hacer afirmaciones causales.
- Recientemente, el **enfoque contrafactual** ha sido adoptado en las ciencias sociales como marco para la inferencia causal.

# Enfoque Contrafactual de la Inferencia Causal

## *Cambios recientes en la investigación en ciencias sociales*

- Históricamente, la **causalidad inversa** y el **sesgo causado por variables omitidas** han sido problemáticos para muchas investigaciones de las ciencias sociales que buscan hacer afirmaciones causales.
- Recientemente, el **enfoque contrafactual** ha sido adoptado en las ciencias sociales como marco para la inferencia causal.
- Esto representa un **gran cambio** en la investigación:

# Enfoque Contrafactual de la Inferencia Causal

## *Cambios recientes en la investigación en ciencias sociales*

- Históricamente, la **causalidad inversa** y el **sesgo causado por variables omitidas** han sido problemáticos para muchas investigaciones de las ciencias sociales que buscan hacer afirmaciones causales.
- Recientemente, el **enfoque contrafactual** ha sido adoptado en las ciencias sociales como marco para la inferencia causal.
- Esto representa un **gran cambio** en la investigación:
  - Ser *más precisos* sobre lo que entendemos por efectos causales.

# Enfoque Contrafactual de la Inferencia Causal

## *Cambios recientes en la investigación en ciencias sociales*

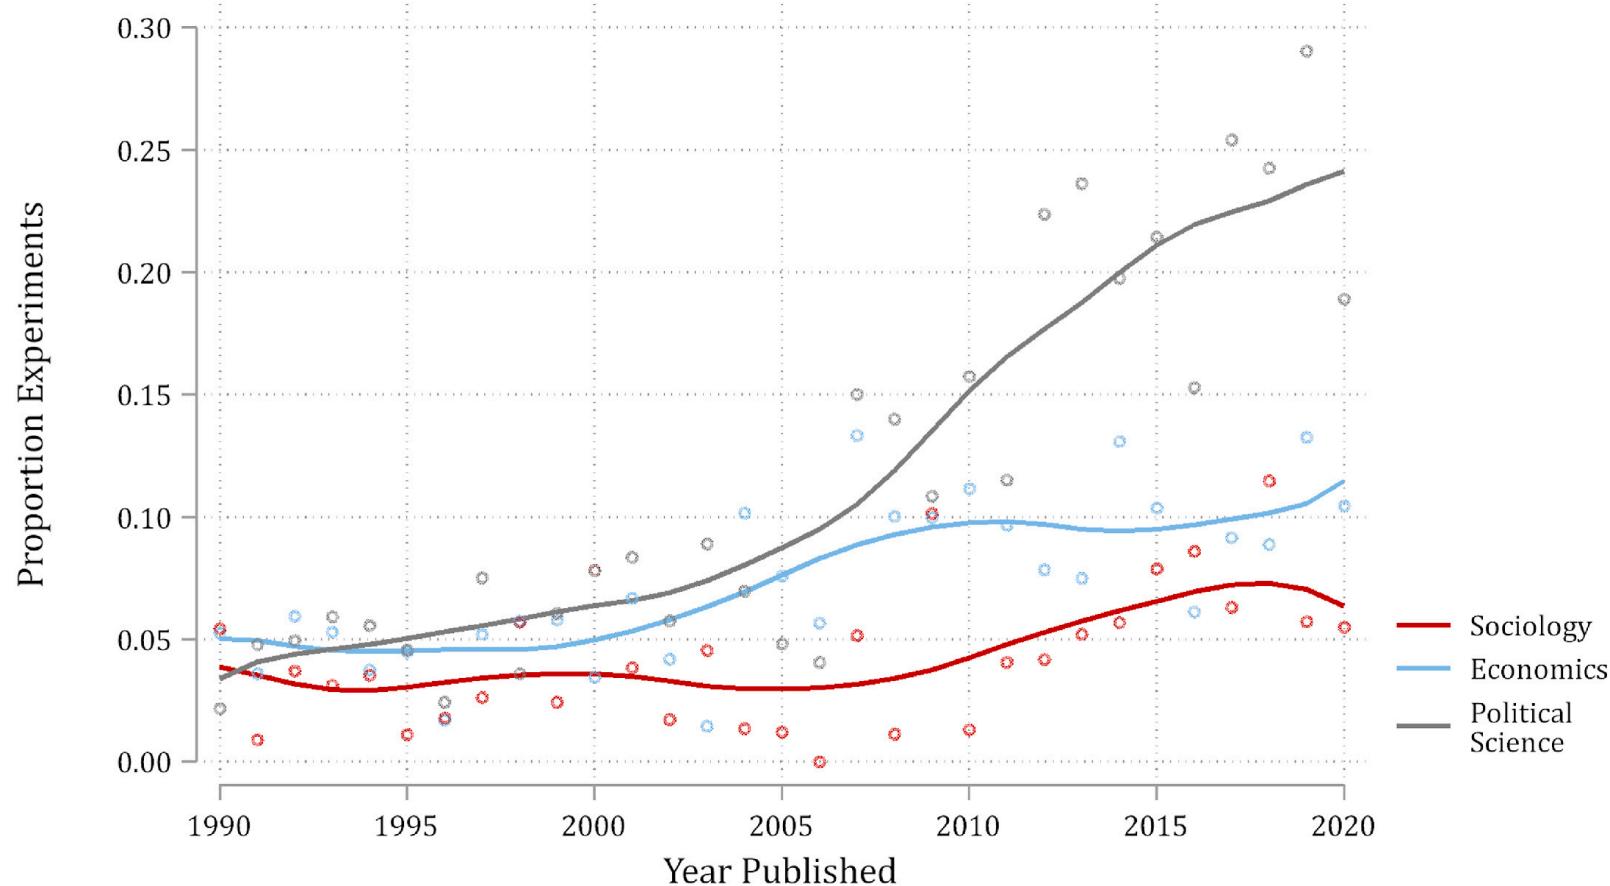
- Históricamente, la **causalidad inversa** y el **sesgo causado por variables omitidas** han sido problemáticos para muchas investigaciones de las ciencias sociales que buscan hacer afirmaciones causales.
- Recientemente, el **enfoque contrafactual** ha sido adoptado en las ciencias sociales como marco para la inferencia causal.
- Esto representa un **gran cambio** en la investigación:
  - Ser *más precisos* sobre lo que entendemos por efectos causales.
  - Uso de aleatorización o de *diseños pseudo-aleatorios*

# Enfoque Contrafactual de la Inferencia Causal

## *Cambios recientes en la investigación en ciencias sociales*

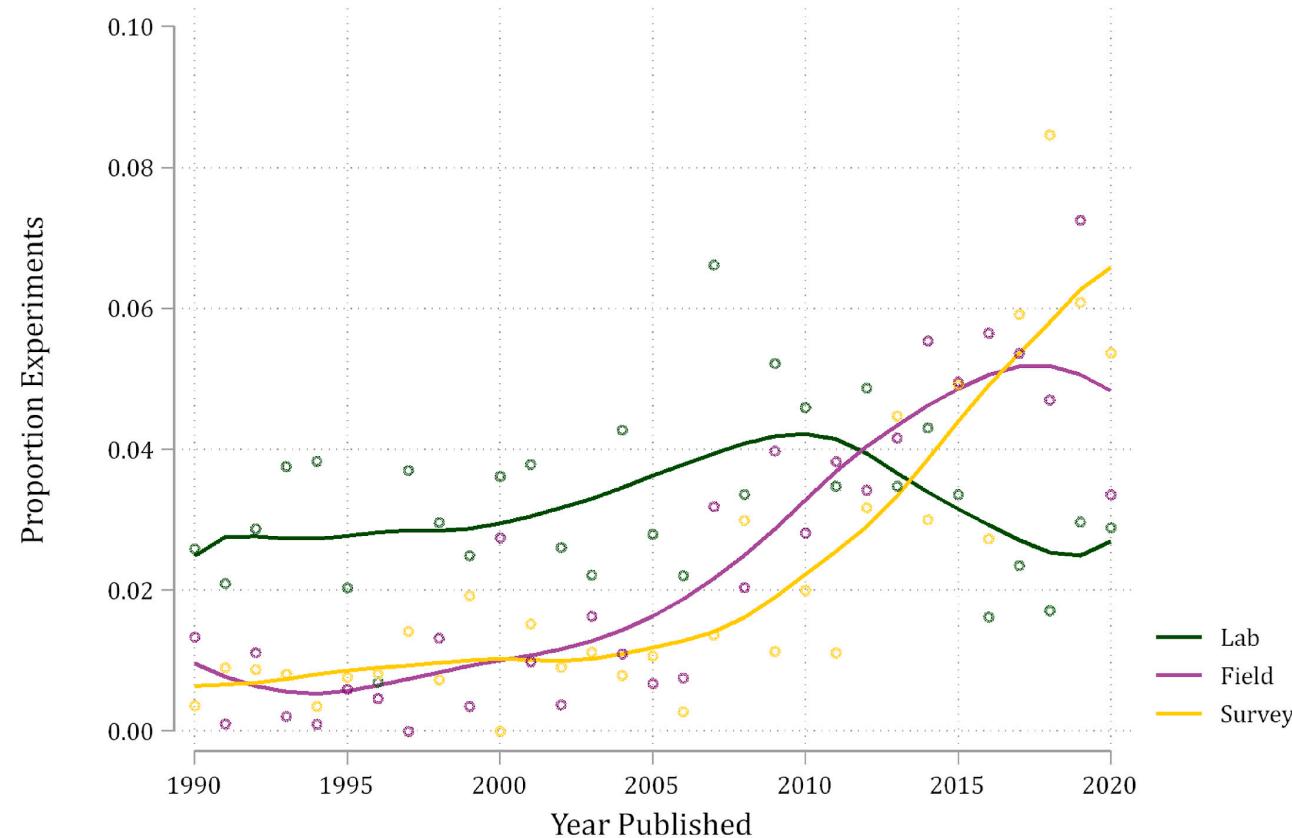
- Históricamente, la **causalidad inversa** y el **sesgo causado por variables omitidas** han sido problemáticos para muchas investigaciones de las ciencias sociales que buscan hacer afirmaciones causales.
- Recientemente, el **enfoque contrafactual** ha sido adoptado en las ciencias sociales como marco para la inferencia causal.
- Esto representa un **gran cambio** en la investigación:
  - Ser *más precisos* sobre lo que entendemos por efectos causales.
  - Uso de aleatorización o de *diseños pseudo-aleatorios*
  - *Más colaboraciones* entre investigadores y profesionales.

# Mayor interés académico en métodos de inferencia causal



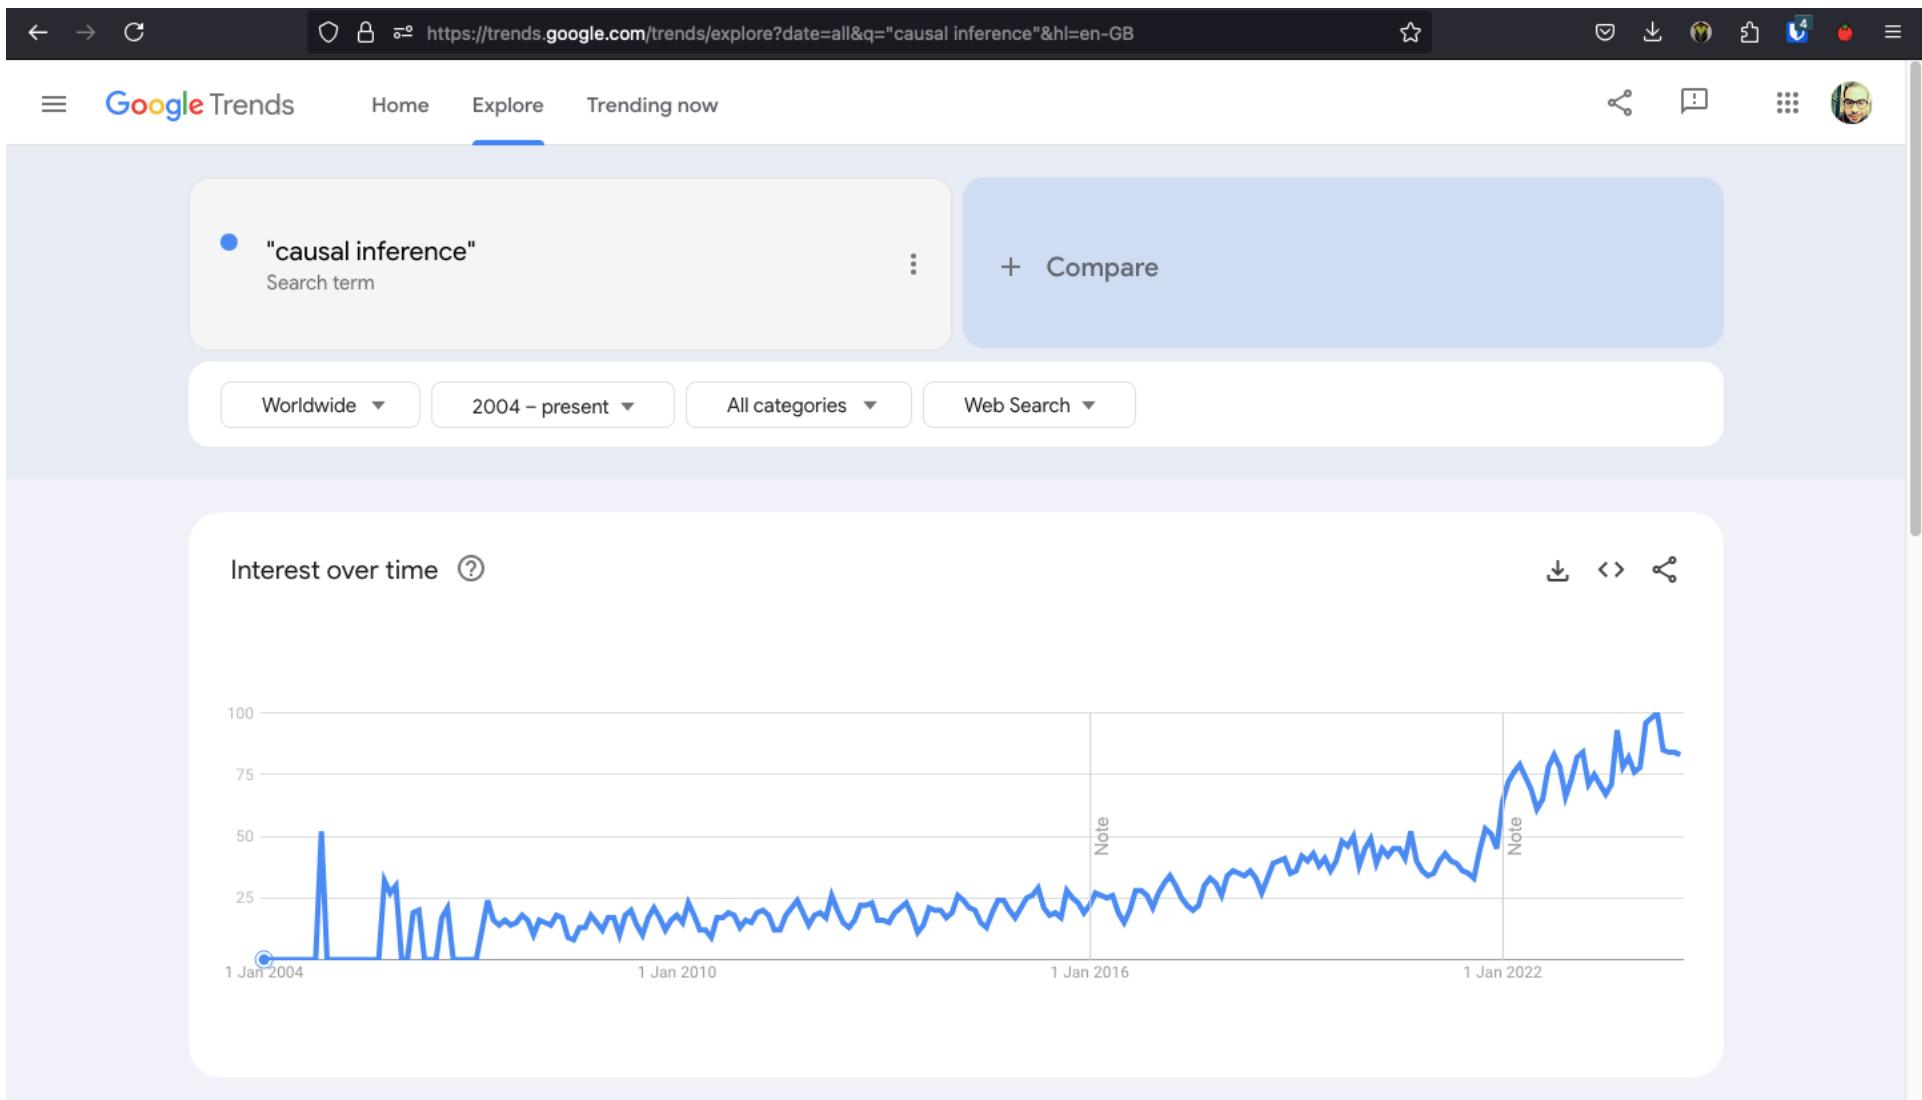
Proporción de artículos publicados que utilizan experimentos en las dos principales revistas de sociología, economía y ciencias políticas (1990-2020). Fuente: Mize and Manago (2022)

# Mayor interés académico en métodos de inferencia causal



Proporción de artículos publicados que utilizan experimentos en sociología, ciencias políticas y economía según el tipo de método experimental utilizado (1990-2020). Fuente: Mize and Manago (2022)

# Mayor interés en métodos de inferencia causal



# Premios Nobel en Economía

*Banerjee, Duflo y Kremer*

https://www.nobelprize.org/prizes/economic-sciences/2019/summary/

THE NOBEL PRIZE

Nobel Prizes & laureates About Stories Educational Events & museums

Search

The Sveriges Riksbank Prize in Economic Sciences in Memory of Alfred Nobel 2019

Summary

Laureates

Abhijit Banerjee  
Esther Duflo  
Michael Kremer

Prize announcement

Press release

Popular information

Advanced information

Award ceremony video

Award ceremony speech

Share this

© Nobel Media. Photo: A. Mahmoud Abhijit Banerjee  
Prize share: 1/3

© Nobel Media. Photo: A. Mahmoud Esther Duflo  
Prize share: 1/3

© Nobel Media. Photo: A. Mahmoud Michael Kremer  
Prize share: 1/3



The Sveriges Riksbank Prize in Economic Sciences in Memory of Alfred Nobel 2019 was awarded jointly to Abhijit Banerjee, Esther Duflo and Michael Kremer "for their experimental approach to alleviating global poverty"

# Premios Nobel en Economía

*Card, Angrist y Imbens*

https://www.nobelprize.org/prizes/economic-sciences/2021/summary/

THE NOBEL PRIZE

Nobel Prizes & laureates About Stories Educational Events & museums

The Sveriges Riksbank Prize in Economic Sciences in Memory of Alfred Nobel 2021

Summary Laureates

David Card  
Joshua D. Angrist  
Guido W. Imbens

Prize announcement Press release

Popular information Advanced information

Award ceremony video Award ceremony speech

Share this

  
© Nobel Prize Outreach. Photo:  
Clément Morin  
**David Card**  
Prize share: 1/2

  
© Nobel Prize Outreach. Photo:  
Stefan Bladh  
**Joshua D. Angrist**  
Prize share: 1/4

  
© Nobel Prize Outreach. Photo:  
Stefan Bladh  
**Guido W. Imbens**  
Prize share: 1/4

The Sveriges Riksbank Prize in Economic Sciences in Memory of Alfred Nobel 2021 was divided, one half awarded to David Card "for his empirical contributions to labour economics", the other half jointly to Joshua D. Angrist and Guido W. Imbens "for their methodological contributions to the analysis of causal relationships"

# ¿Qué es la causalidad?



“X causó Y” es una afirmación sobre lo que no sucedió

“X causó Y” es una afirmación sobre lo que no sucedió

- En el enfoque contrafactual:

“X causó Y” es una afirmación sobre lo que no sucedió

- En el enfoque contrafactual: “Si X no hubiera ocurrido,

“X causó Y” es una afirmación sobre lo que no sucedió

- En el enfoque contrafactual: “Si X no hubiera ocurrido, entonces Y no habría ocurrido.”

# “X causó Y” es una afirmación sobre lo que no sucedió

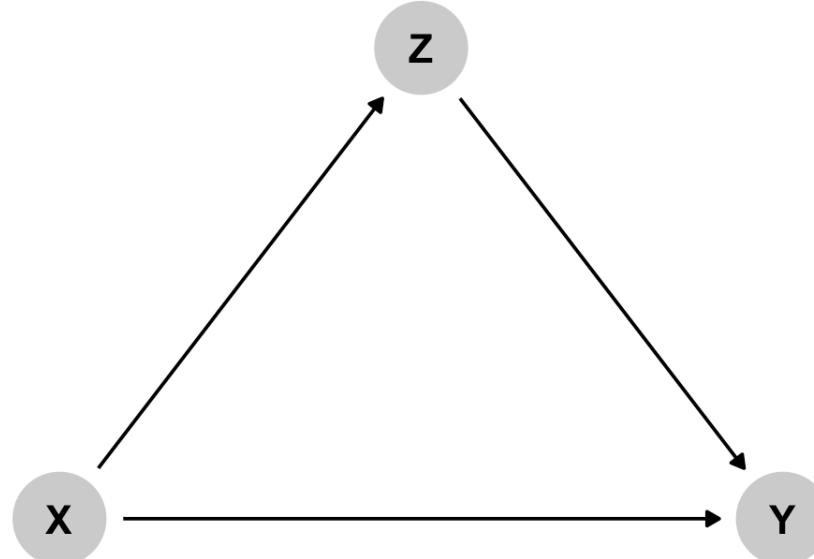
- En el enfoque contrafactual: “Si X no hubiera ocurrido, entonces Y no habría ocurrido.”
- Los experimentos nos ayudan a aprender acerca de las afirmaciones contrafactuales y basadas en la manipulación de la causalidad.

# “X causó Y” es una afirmación sobre lo que no sucedió

- En el enfoque contrafactual: “Si X no hubiera ocurrido, entonces Y no habría ocurrido.”
- Los experimentos nos ayudan a aprender acerca de las afirmaciones contrafactuales y basadas en la manipulación de la causalidad.
- No es erróneo conceptualizar “causa” de otra manera. Pero ha sido productivo trabajar en este marco hipotético ([Brady 2008](#)).

# “X causó Y” es una afirmación sobre lo que no sucedió

- En el enfoque contrafactual: “Si X no hubiera ocurrido, entonces Y no habría ocurrido.”
- Los experimentos nos ayudan a aprender acerca de las afirmaciones contrafactuales y basadas en la manipulación de la causalidad.
- No es erróneo conceptualizar “causa” de otra manera. Pero ha sido productivo trabajar en este marco hipotético (Brady 2008).



Directed acyclic graph

# Cómo interpretar “X causa Y” en este enfoque

# Cómo interpretar “X causa Y” en este enfoque

1. “X causa Y” no implica necesariamente que W y V no causen Y: **X es parte de la historia, no toda la historia.** (No se necesita conocer la historia completa para saber si X causa Y).

# Cómo interpretar “X causa Y” en este enfoque

1. “X causa Y” no implica necesariamente que W y V no causen Y: **X es parte de la historia, no toda la historia.** (No se necesita conocer la historia completa para saber si X causa Y).
2. “X causa Y” requiere un **contexto**: los fósforos causan la llama pero requieren oxígeno; las aulas pequeñas mejoran los resultados de las pruebas, pero requieren profesores experimentados y financiación ([Cartwright and Hardie 2012](#)).

# Cómo interpretar “X causa Y” en este enfoque

1. “X causa Y” no implica necesariamente que W y V no causen Y: **X es parte de la historia, no toda la historia.** (No se necesita conocer la historia completa para saber si X causa Y).
2. “X causa Y” requiere un **contexto**: los fósforos causan la llama pero requieren oxígeno; las aulas pequeñas mejoran los resultados de las pruebas, pero requieren profesores experimentados y financiación ([Cartwright and Hardie 2012](#)).
3. “X causa Y” puede significar “Si X ocurre, la probabilidad de Y es mayor que sin que X ocurra”. o “Sin que X ocurra no hay Y”. **Cualquiera de las dos afirmaciones es compatible** con la idea contrafactual.

# Cómo interpretar “X causa Y” en este enfoque

# Cómo interpretar “X causa Y” en este enfoque

4. No es necesario conocer el mecanismo para establecer que X causa Y. El mecanismo puede ser complejo y puede involucrar probabilidad: X causa Y a veces debido a A y a veces debido a B.

# Cómo interpretar “X causa Y” en este enfoque

4. No es necesario conocer el mecanismo para establecer que X causa Y. El mecanismo puede ser complejo y puede involucrar probabilidad: X causa Y a veces debido a A y a veces debido a B.
5. La causalidad contrafactual no requiere “una secuencia espacio-temporal continua de intermediarios causales”

# Cómo interpretar “X causa Y” en este enfoque

4. No es necesario conocer el mecanismo para establecer que X causa Y. El mecanismo puede ser complejo y puede involucrar probabilidad: X causa Y a veces debido a A y a veces debido a B.
5. La causalidad contrafactual no requiere “una secuencia espacio-temporal continua de intermediarios causales”
6. Correlación *casi nunca* es igual a causalidad.

# Ejercicio: equinácea

# Ejercicio: equinácea

- Un amigo suyo dice que tomar equinácea (un remedio tradicional) reduce la duración de los resfriados.

# Ejercicio: equinácea

- Un amigo suyo dice que tomar equinácea (un remedio tradicional) reduce la duración de los resfriados.
- Si adoptamos un enfoque contrafactual, ¿qué nos dice implícitamente esta afirmación sobre el contrafactual? ¿Qué otros contrafactuals podrían ser posibles y por qué?

# Ejercicio: equinácea

- Un amigo suyo dice que tomar equinácea (un remedio tradicional) reduce la duración de los resfriados.
- Si adoptamos un enfoque contrafactual, ¿qué nos dice implícitamente esta afirmación sobre el contrafactual? ¿Qué otros contrafactuals podrían ser posibles y por qué?
- El contrafactual implícito es: **“Si yo no hubiera tomado equinácea, mi resfriado habría durado más tiempo”**.

# Ejercicio: equinácea

- Un amigo suyo dice que tomar equinácea (un remedio tradicional) reduce la duración de los resfriados.
- Si adoptamos un enfoque contrafactual, ¿qué nos dice implícitamente esta afirmación sobre el contrafactual? ¿Qué otros contrafactuals podrían ser posibles y por qué?
- El contrafactual implícito es: *"Si yo no hubiera tomado equinácea, mi resfriado habría durado más tiempo"*.
- ¡Pero este no es el único contrafactual posible!

# Ejercicio: equinácea

- Un amigo suyo dice que tomar equinácea (un remedio tradicional) reduce la duración de los resfriados.
- Si adoptamos un enfoque contrafactual, ¿qué nos dice implícitamente esta afirmación sobre el contrafactual? ¿Qué otros contrafactuals podrían ser posibles y por qué?
- El contrafactual implícito es: “*Si yo no hubiera tomado equinácea, mi resfriado habría durado más tiempo*”.
- ¡Pero este no es el único contrafactual posible!
  - Por ejemplo, podría ser: “*Si yo no hubiera tomado equinácea, mi resfriado habría durado lo mismo*”. (“variabilidad natural”, “placebo” o “nulo”)

# Ejercicio: equinácea

- Un amigo suyo dice que tomar equinácea (un remedio tradicional) reduce la duración de los resfriados.
- Si adoptamos un enfoque contrafactual, ¿qué nos dice implícitamente esta afirmación sobre el contrafactual? ¿Qué otros contrafactuals podrían ser posibles y por qué?
- El contrafactual implícito es: “*Si yo no hubiera tomado equinácea, mi resfriado habría durado más tiempo*”.
- ¡Pero este no es el único contrafactual posible!
  - Por ejemplo, podría ser: “*Si yo no hubiera tomado equinácea, mi resfriado habría durado lo mismo*”. (“variabilidad natural”, “placebo” o “nulo”)
  - “*Si yo no hubiera tomado equinácea, mi resfriado habría durado menos tiempo*”. (“efecto negativo de la equinácea”)

# Resultados potenciales

# Resultados potenciales

# Resultados potenciales

- Para cada unidad asumimos que hay dos valores posteriores al tratamiento:  $Y_i(1)$  y  $Y_i(0)$ .

# Resultados potenciales

- Para cada unidad asumimos que hay dos valores posteriores al tratamiento:  $Y_i(1)$  y  $Y_i(0)$ .
- $Y_i(1)$  es el resultado que **obtendría** la unidad *si* recibe el tratamiento ( $T_i = 1$ ).

# Resultados potenciales

- Para cada unidad asumimos que hay dos valores posteriores al tratamiento:  $Y_i(1)$  y  $Y_i(0)$ .
- $Y_i(1)$  es el resultado que **obtendría** la unidad *si* recibe el tratamiento ( $T_i = 1$ ).
- $Y_i(0)$  es el resultado que **obtendría** la unidad *si* no recibe el tratamiento ( $T_i = 0$ ).

# Resultados potenciales

- Para cada unidad asumimos que hay dos valores posteriores al tratamiento:  $Y_i(1)$  y  $Y_i(0)$ .
- $Y_i(1)$  es el resultado que **obtendría** la unidad *si* recibe el tratamiento ( $T_i = 1$ ).
- $Y_i(0)$  es el resultado que **obtendría** la unidad *si* no recibe el tratamiento ( $T_i = 0$ ).



# Definición de efecto causal

# Definición de efecto causal

- El **efecto causal** del tratamiento (relativo al control) es:

$$\tau_i = Y_i(1) - Y_i(0)$$

# Definición de efecto causal

- El **efecto causal** del tratamiento (relativo al control) es:  
 $\tau_i = Y_i(1) - Y_i(0)$
- Tenga en cuenta que hemos pasado a usar  $T$  para indicar nuestro **tratamiento** (cuyo efecto queremos saber).  $X$  se utilizará para las variables explicatorias.

# Características clave de esta definición de efecto causal

1. Debe **definir la condición de control** para definir un efecto causal.
  - Digamos que  $T = 1$  significa una reunión comunitaria para discutir la salud pública. ¿Es  $T = 0$  que no hay reunión en absoluto? ¿Es  $T = 0$  una reunión comunitaria sobre un tema diferente? ¿Es  $T = 0$  un volante sobre salud pública?
  - La frase “efecto causal de  $T$  en  $Y$ ” no tiene sentido sin saber qué significa no tener  $T$ .
2. Cada unidad individual  $i$  tiene su propio efecto causal  $\tau_i$ .
3. Pero no podemos medir el efecto causal a nivel individual, porque no podemos observar  $Y_i(1)$  y  $Y_i(0)$  al mismo tiempo. Esto se conoce como el **problema fundamental de la inferencia causal**. Lo que observamos es  $Y_i$ :

$$Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$$

Suponga que sabemos el valor de  $Y_i(1)$  y  $Y_i(0)$

*¡Esto no es posible!*

	$i$	$Y_i(1)$	$Y_i(0)$	$\tau_i$
	Andrei	1	1	0
	Bamidele	1	0	1
	Claire	0	0	0
	Deepal	0	1	-1

- Conocemos el efecto del tratamiento para cada individuo.
- Nótese la heterogeneidad en los efectos del tratamiento a nivel individual.
- Pero solo sabemos del valor de una de los resultados potenciales para cada individuo como máximo, lo que significa que no conocemos estos efectos del tratamiento.

# Efecto causal promedio

- Si bien no podemos medir el efecto causal individual,  $\tau_i = Y_i(1) - Y_i(0)$ , podemos asignar sujetos al azar a las condiciones de tratamiento y control para estimar el **efecto causal promedio**,  $\bar{\tau}_i$ :

$$\bar{\tau}_i = \frac{1}{N} \sum_{i=1}^N (Y_i(1) - Y_i(0)) = \overline{Y_i(1) - Y_i(0)}$$

- El efecto causal promedio también se conoce como **efecto promedio del tratamiento** (average treatment effect, ATE).
- Explicaremos en más detalle cómo calcularlo después de discutir la asignación aleatoria del tratamiento en la siguiente sección.

# Estimandos y preguntas causales

- Antes de discutir la aleatorización y cómo esta nos permite estimar el ATE, tengan en cuenta que el ATE es un tipo de estimando.
- Un estimando es una **cantidad sobre la que se desea aprender** (a partir de los datos). Es el objetivo de la investigación que *ustedes* establecieron.
- Ser preciso con la pregunta de investigación significa ser preciso con el estimando. Para preguntas causales, esto significa especificar:
  - La variable de resultado
  - Las condiciones de tratamiento y control
  - La población de estudio

# Otros tipos de estimandos que pueden interesarle

# Otros tipos de estimandos que pueden interesarle

- El ATE para un subgrupo en particular, también conocido como efecto promedio condicional del tratamiento (conditional average treatment effect, CATE)

# Otros tipos de estimandos que pueden interesarle

- El ATE para un subgrupo en particular, también conocido como efecto promedio condicional del tratamiento (conditional average treatment effect, CATE)
- Diferencias en el CATE: diferencias en el efecto promedio del tratamiento para un grupo en comparación con otro grupo.

# Otros tipos de estimandos que pueden interesarle

- El ATE para un subgrupo en particular, también conocido como efecto promedio condicional del tratamiento (conditional average treatment effect, CATE)
- Diferencias en el CATE: diferencias en el efecto promedio del tratamiento para un grupo en comparación con otro grupo.
- El ATE solo para las unidades tratadas, también conocido como efecto promedio del tratamiento en los tratados (average treatment effect on the treated, ATT)

# Otros tipos de estimandos que pueden interesarle

- El ATE para un subgrupo en particular, también conocido como efecto promedio condicional del tratamiento (conditional average treatment effect, CATE)
- Diferencias en el CATE: diferencias en el efecto promedio del tratamiento para un grupo en comparación con otro grupo.
- El ATE solo para las unidades tratadas, también conocido como efecto promedio del tratamiento en los tratados (average treatment effect on the treated, ATT)
- El ATE local (ATE Local, LATE). “Local” = aquellos cuyo estado de tratamiento cambiaría por el estímulo de un diseño de estímulo (también conocido como efecto causal promedio del cumplidor) o aquellos en el vecindario de una discontinuidad para un diseño de regresión discontinua.

# Otros tipos de estimandos que pueden interesarle

- El ATE para un subgrupo en particular, también conocido como efecto promedio condicional del tratamiento (conditional average treatment effect, CATE)
- Diferencias en el CATE: diferencias en el efecto promedio del tratamiento para un grupo en comparación con otro grupo.
- El ATE solo para las unidades tratadas, también conocido como efecto promedio del tratamiento en los tratados (average treatment effect on the treated, ATT)
- El ATE local (ATE Local, LATE). “Local” = aquellos cuyo estado de tratamiento cambiaría por el estímulo de un diseño de estímulo (también conocido como efecto causal promedio del cumplidor) o aquellos en el vecindario de una discontinuidad para un diseño de regresión discontinua.
- Analizaremos los estimandos en detalle en el módulo de estimaciones y estimadores.

# Aleatorización de la asignación del tratamiento



# Aleatorización de la asignación del tratamiento

# Aleatorización de la asignación del tratamiento

- La aleatorización significa que cada observación tiene una **probabilidad conocida de asignación a condiciones experimentales entre 0 y 1.**

# Aleatorización de la asignación del tratamiento

- La aleatorización significa que cada observación tiene una **probabilidad conocida de asignación a condiciones experimentales entre 0 y 1.**
  - Ninguna unidad de la muestra experimental se asigna al tratamiento **con total certeza** (probabilidad = 1) o al control con total certeza (probabilidad = 0).

# Aleatorización de la asignación del tratamiento

- La aleatorización significa que cada observación tiene una **probabilidad conocida de asignación a condiciones experimentales entre 0 y 1.**
  - Ninguna unidad de la muestra experimental se asigna al tratamiento **con total certeza** ( $\text{probabilidad} = 1$ ) o al control **con total certeza** ( $\text{probabilidad} = 0$ ).
- Las probabilidad de asignación al tratamiento puede **variar para cada unidad.**

# Aleatorización de la asignación del tratamiento

- La aleatorización significa que cada observación tiene una **probabilidad conocida de asignación a condiciones experimentales entre 0 y 1.**
  - Ninguna unidad de la muestra experimental se asigna al tratamiento **con total certeza** (probabilidad = 1) o al control **con total certeza** (probabilidad = 0).
- Las probabilidad de asignación al tratamiento puede **variar para cada unidad.**
  - Por ejemplo, la probabilidad puede variar según el grupo: las mujeres pueden tener un 25% de probabilidad de ser asignadas al tratamiento, mientras que los hombres tienen una probabilidad diferente.

# Aleatorización de la asignación del tratamiento

- La aleatorización significa que cada observación tiene una **probabilidad conocida de asignación a condiciones experimentales entre 0 y 1.**
  - Ninguna unidad de la muestra experimental se asigna al tratamiento **con total certeza** (probabilidad = 1) o al control **con total certeza** (probabilidad = 0).
- Las probabilidad de asignación al tratamiento puede **variар para cada unidad.**
  - Por ejemplo, la probabilidad puede variar según el grupo: las mujeres pueden tener un 25% de probabilidad de ser asignadas al tratamiento, mientras que los hombres tienen una probabilidad diferente.
  - Incluso puede variar de una persona a otra, claro está que eso complicaría el análisis.

# Asignación aleatoria versus muestreo aleatorio

# Asignación aleatoria versus muestreo aleatorio

- Aleatorización (del tratamiento): **asignación de sujetos** con probabilidad conocida a condiciones experimentales.

# Asignación aleatoria versus muestreo aleatorio

- Aleatorización (del tratamiento): **asignación de sujetos** con probabilidad conocida a condiciones experimentales.
  - Esta asignación aleatoria de tratamiento puede combinarse con **cualquier tipo de muestra** (muestra aleatoria, muestra de conveniencia, etc.).

# Asignación aleatoria versus muestreo aleatorio

- Aleatorización (del tratamiento): **asignación de sujetos** con probabilidad conocida a condiciones experimentales.
  - Esta asignación aleatoria de tratamiento puede combinarse con **cualquier tipo de muestra** (muestra aleatoria, muestra de conveniencia, etc.).
  - Pero el tamaño y otras características de su muestra afectarán su poder y su capacidad para extraer su hallazgo a otras poblaciones.

# Asignación aleatoria versus muestreo aleatorio

- Aleatorización (del tratamiento): **asignación de sujetos** con probabilidad conocida a condiciones experimentales.
  - Esta asignación aleatoria de tratamiento puede combinarse con **cualquier tipo de muestra** (muestra aleatoria, muestra de conveniencia, etc.).
  - Pero el tamaño y otras características de su muestra afectarán su poder y su capacidad para extraer su hallazgo a otras poblaciones.
- Muestreo aleatorio (de la población): **selección de sujetos de una población** a la muestra con probabilidad conocida.

# La aleatorización es poderosa (1)

- Queremos conocer el valor del ATE,  $\tau_i = \overline{Y_i(1) - Y_i(0)}$ .
- Aprovecharemos el hecho de que la media de diferencias es igual a la diferencia de medias:

$$\text{ATE} = \overline{Y_i(1) - Y_i(0)} = \overline{Y_i(1)} - \overline{Y_i(0)}$$

# La aleatorización es poderosa (2)

- Asignamos *aleatoriamente* algunas de nuestras unidades al tratamiento. Para estas unidades tratadas, medimos el resultado  $Y_i|T_i = 1$ , que es lo mismo que  $Y_i(1)$  para estas unidades que asignamos al tratamiento.
- Debido a que estas unidades se asignaron al azar al tratamiento, estos  $Y_i = Y_i(1)$  para las unidades tratadas representan los  $Y_i(1)$  para todas nuestras unidades.
- En valor esperado (o en promedio a través de experimentos repetidos (escrito  $E_R[]$ )):

$$E_R[\overline{Y_i|T_i = 1}] = \overline{Y_i(1)}$$

- $\overline{Y|T_i = 1}$  es un estimador insesgado de la media poblacional de resultados potenciales bajo el tratamiento.
- La misma lógica se aplica a las unidades asignadas aleatoriamente al control:

$$E_R[\overline{Y_i|T_i = 0}] = \overline{Y_i(0)}$$

# La aleatorización es poderosa (3)

- Entonces podemos escribir el estimador para el ATE:

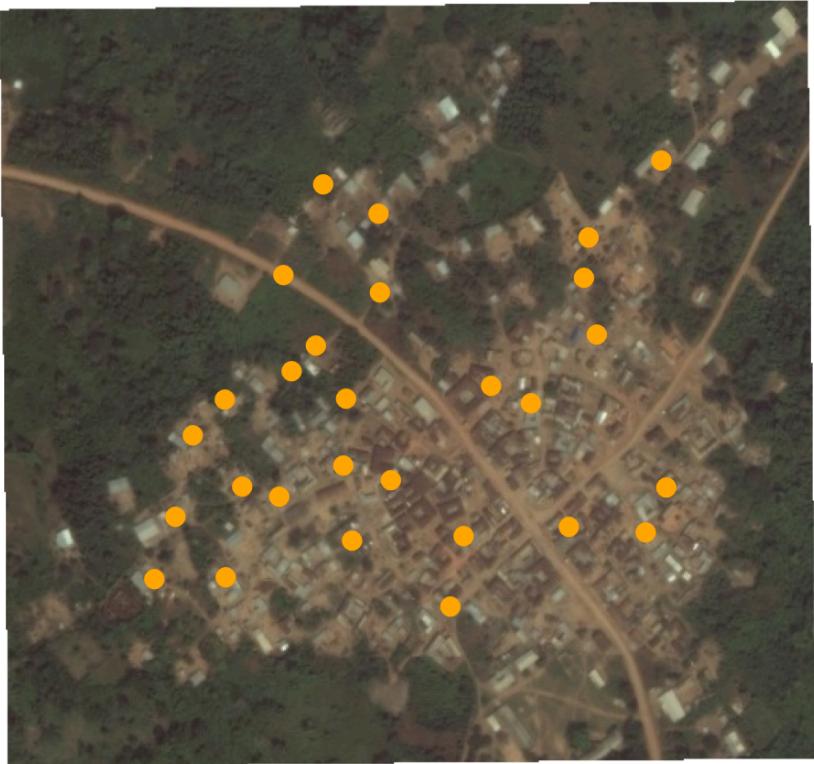
$$\hat{\tau}_i = (\overline{Y_i(1)}|T_i = 1) - (\overline{Y_i(0)}|T_i = 0)$$

- En valor esperado, o en promedio en experimentos repetidos,  $\hat{\tau}_i$  es igual al ATE:

$$E_R[Y_i|T_i = 1] - E_R[Y_i|T_i = 0] = \overline{Y_i(1)} - \overline{Y_i(0)}$$

- Entonces podemos tomar la diferencia de estos estimadores insesgados de  $\overline{Y_i(1)}$  y  $\overline{Y_i(0)}$  para obtener una estimación insesgada del ATE.

# Muestreo aleatorio



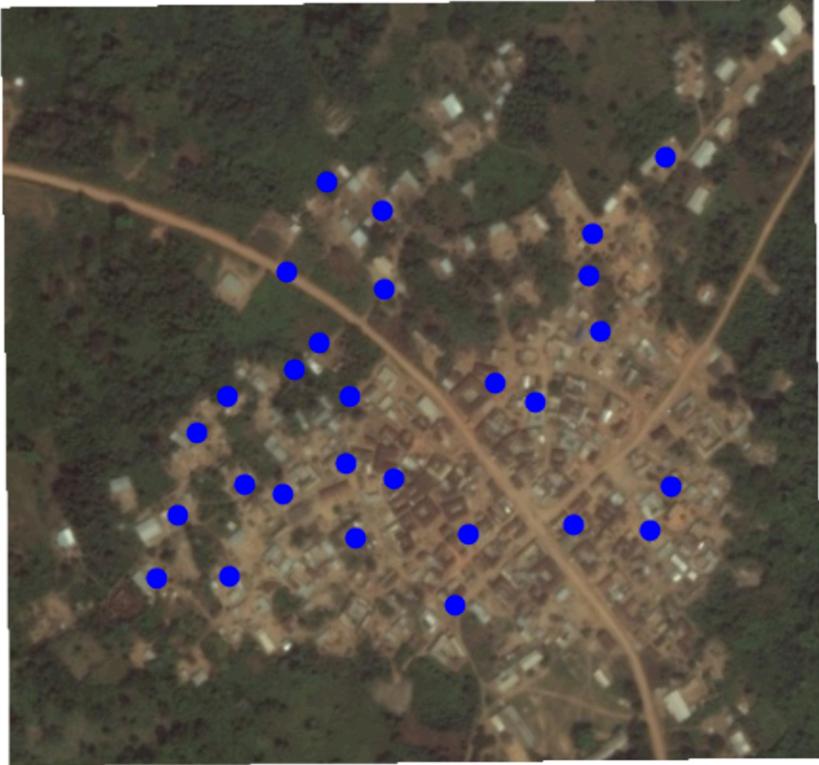
# Resultados potenciales

Cada hogar  $i$  tiene  $Y_i(0)$  y  $Y_i(1)$ .



# Resultados potenciales

Cada hogar  $i$  tiene  $Y_i(0)$  y  $Y_i(1)$ .

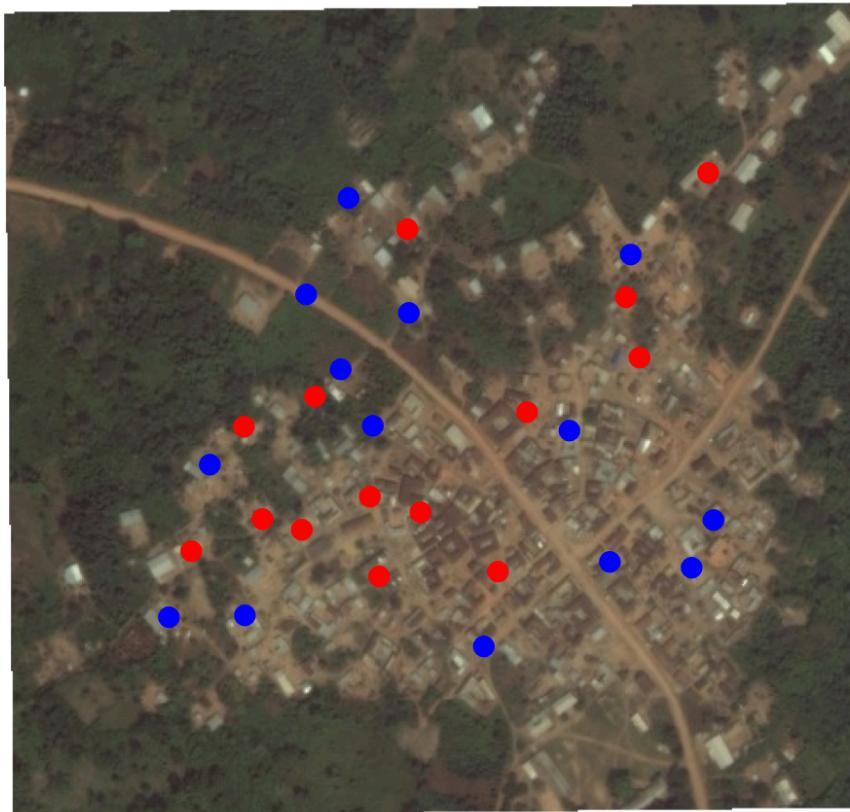


# Resultados potenciales

Cada hogar  $i$  tiene  $Y_i(0)$  y  $Y_i(1)$ .



# Asignación aleatoria a la condición roja (1) o azul (0)



# Tres supuestos clave

Para hacer afirmaciones causales con un experimento (o para juzgar si creemos en las afirmaciones de un estudio), necesitamos tres supuestos básicos:

# Tres supuestos clave

Para hacer afirmaciones causales con un experimento (o para juzgar si creemos en las afirmaciones de un estudio), necesitamos tres supuestos básicos:

- **Asignación aleatoria de sujetos al tratamiento**, lo que implica que recibir el tratamiento es estadísticamente independiente de los resultados potenciales de los sujetos.

# Tres supuestos clave

Para hacer afirmaciones causales con un experimento (o para juzgar si creemos en las afirmaciones de un estudio), necesitamos tres supuestos básicos:

- **Asignación aleatoria de sujetos al tratamiento**, lo que implica que recibir el tratamiento es estadísticamente independiente de los resultados potenciales de los sujetos.
- Supuesto de estabilidad del valor bajo tratamiento para cada unidad (**SEVTU**).

# Tres supuestos clave

Para hacer afirmaciones causales con un experimento (o para juzgar si creemos en las afirmaciones de un estudio), necesitamos tres supuestos básicos:

- **Asignación aleatoria de sujetos al tratamiento**, lo que implica que recibir el tratamiento es estadísticamente independiente de los resultados potenciales de los sujetos.
- Supuesto de estabilidad del valor bajo tratamiento para cada unidad (**SEVTU**).
- **Excluibilidad**, que significa que la asignación a un grupo de tratamiento afecta los resultados de un sujeto únicamente a través de la recepción del tratamiento en sí.

# Supuesto clave: SEVTU, parte 1

1. **No interferencia:** la resultado potencial de un sujeto refleja solo si ese sujeto recibe el tratamiento. No se ve afectado por cómo se asigna el tratamiento a otros sujetos.

- Una violación clásica es el caso de las vacunas y sus efectos secundarios.
- Imaginen que yo fui asignado a la condición de control (sin vacuna). Que me enferme ( $Y_i(0)$ ), depende de la asignación al tratamiento de otras personas (en caso de que sí tomen la vacuna), ¡es como si tuviera dos  $Y_i(0)$  diferentes!
- SEVTU (= Supuesto de estabilidad del valor bajo el tratamiento para cada unidad )

# Supuesto clave: SEVTU, parte 2

## 2. No hay variaciones ocultas del tratamiento

- Digamos que el tratamiento es vacunarse, pero hay dos tipos de vacunas y tienen diferentes ingredientes.
- Un ejemplo de una violación a este supuesto es que el que me enferme luego de haberme puesto la vacuna ( $Y_i(1)$ ) dependa del tipo de vacuna que recibí. ¡Habrá dos  $Y_i(1)$  diferentes!

# Supuesto clave: Excludibilidad

- La asignación al tratamiento no tiene ningún efecto sobre los resultados, excepto el que puede tener a través del tratamiento.
  - Es importante definir el tratamiento con precisión.
  - Es importante también mantener la simetría entre los grupos de tratamiento y control (por ejemplo, ocultando cuál fue la asignación al tratamiento, tener los mismos procedimientos de recopilación de datos para todos los sujetos del estudio, etc.), de modo que la asignación al tratamiento solo afecte el tratamiento recibido, no otras cosas como las interacciones con los investigadores que no deberían ser parte del tratamiento.

# La aleatorización es poderosa (4)

- Si la intervención es aleatoria, entonces quién recibe o no la intervención no está relacionado con las características personales de los posibles destinatarios.
- La aleatorización hace que aquellos que fueron seleccionados al azar para no recibir la intervención sean buenos sustitutos del contrafactual para aquellos que fueron seleccionados al azar para recibir el tratamiento, y viceversa.
- Nos debemos preocupar con esto si la intervención no fue aleatorizada (= un estudio observacional).

# Estudios aleatorizados frente a observacionales

# Diferentes tipos de estudios

# Diferentes tipos de estudios

- Estudios aleatorizados

# Diferentes tipos de estudios

- Estudios aleatorizados
  - Aleatorizar el tratamiento y luego medir los resultados

# Diferentes tipos de estudios

- Estudios aleatorizados
  - Aleatorizar el tratamiento y luego medir los resultados
- Estudios observacionales

# Diferentes tipos de estudios

- Estudios aleatorizados
  - Aleatorizar el tratamiento y luego medir los resultados
- Estudios observacionales
  - El tratamiento no se asigna al azar. *Se observa, pero no se manipula.*

# Ejercicio: aprendiendo acerca de sus conocimientos previos

**Discutir en grupos pequeños:** Ayúdenme a diseñar el próximo proyecto para responder una de estas preguntas (o una de sus propias preguntas causales). Solamente planteen las características claves de dos diseños: uno observacional y el otro aleatorio.

Preguntas de investigación de ejemplo:

- ¿Aumentan la confianza y la coperación los proyectos de reconstrucción impulsados por la comunidad en Liberia? Ver: [Informe 40 de políticas públicas de EGAP](#)
- ¿Puede el monitoreo comunitario aumentar el uso de clínicas y disminuir la mortalidad infantil en Uganda? Puede ver: [Informe 58 de políticas públicas de EGAP](#)

# Ejercicio: estudios observacionales versus estudios aleatorizados

## Tareas:

1. Esbocen un diseño de un estudio observacional ideal (sin aleatorización, sin control por parte del investigador pero con recursos infinitos para la recopilación de datos). ¿Cuáles son las preguntas que haría un lector crítico frente a la afirmación de que sus resultado reflejan una relación causal?
2. Esbocen un diseño de estudio experimental ideal (que incluya aleatorización). ¿Cuáles son las preguntas que haría un lector crítico frente a la afirmación de que sus resultado reflejan una relación causal?

# Discutir

- ¿Cuáles fueron los componentes clave y las fortalezas y debilidades de los estudios aleatorizados?
- ¿Cuáles fueron los componentes clave y las fortalezas y debilidades de los estudios observacionales?

# Generalizabilidad y validez externa

# Generalizabilidad y validez externa

- La aleatorización aporta una alta validez interna a un estudio: confianza en que hemos aprendido el efecto causal de un tratamiento en una variable de resultado.

# Generalizabilidad y validez externa

- La aleatorización aporta una alta validez interna a un estudio: confianza en que hemos aprendido el efecto causal de un tratamiento en una variable de resultado.
- Pero el hallazgo de un estudio en particular en un lugar particular y en un momento particular puede no ser válido en otros entornos (es decir, validez externa).

# Generalizabilidad y validez externa

- La aleatorización aporta una alta validez interna a un estudio: confianza en que hemos aprendido el efecto causal de un tratamiento en una variable de resultado.
- Pero el hallazgo de un estudio en particular en un lugar particular y en un momento particular puede no ser válido en otros entornos (es decir, validez externa).
- Esta es una preocupación general, no solo una preocupación para los estudios aleatorizados.

# Generalizabilidad y validez externa

- La aleatorización aporta una alta validez interna a un estudio: confianza en que hemos aprendido el efecto causal de un tratamiento en una variable de resultado.
- Pero el hallazgo de un estudio en particular en un lugar particular y en un momento particular puede no ser válido en otros entornos (es decir, validez externa).
- Esta es una preocupación general, no solo una preocupación para los estudios aleatorizados.
- [La iniciativa Metaketa de EGAP's](#) trabaja para acumular conocimientos mediante la planificación previa de un metanálisis de múltiples estudios que tienen una alta validez interna debido a la aleatorización.

# Referencias

Informe 40 de políticas públicas de EGAP: Asistencia para el desarrollo y la capacidad de acción colectiva

Informe 50 de políticas públicas de EGAP: ¿Funciona la rendición de cuentas que parte desde las bases sociales?

Brady, Henry E. 2008. "Causation and Explanation in Social Science." In *The Oxford Handbook of Political Science*.

<https://www.oxfordhandbooks.com/view/10.1093/oxfordhb/9780199286546.001.0001/oxfordhb-9780199286546-e-10>.

Cartwright, Nancy, and Jeremy Hardie. 2012. *Evidence-based policy: a practical guide to doing it better*. Oxford University Press.

Mize, Trenton D, and Bianca Manago. 2022. "The Past, Present, and Future of Experimental Methods in the Social Sciences." *Social Science Research* 108: 102799.