

# Amenazas a la validez interna de los experimentos aleatorizados

*Cómo (intentar) evitar que tu experimento se convierta en un desastre*


Danilo Freire

danilo.freire@emory.edu

Emory University

# Puntos clave de esta presentación

- Deserción (variables de resultado con datos faltantes)
- Incumplimiento
- Derrame
- Efecto Hawthorne
- Tratamiento diferencial de los distintos brazos de tratamiento



# Deserción

# Deserción (variables de resultado con datos faltantes)

## *Otro problema de datos faltantes*

- **Deserción**: Pérdida de participantes antes de la finalización del estudio
- Dos tipos principales:
  - **Deserción aleatoria**: La ausencia de datos no está relacionada con el tratamiento/resultado
  - **Deserción no aleatoria/sistemática**: La ausencia de datos se correlaciona con otras variables
- Impactos:
  - Reducción del **poder estadístico** 📉
  - Potencial **sesgo de selección** que amenaza la validez
  - **Generalización** comprometida 🌐



**Non-random  
attrition**

**Random  
attrition**

# Deserción en experimentos

## *Datos de resultado faltantes*

- Cuando la **deserción** se correlaciona con el tratamiento, **puede sesgar las estimaciones**
- Varios factores pueden conducir a la **deserción**:
  - **Incumplimiento**: La intervención es demasiado engorrosa, injusta o ineficaz
  - **Fatiga de encuesta**: Los participantes pierden interés con el tiempo
  - **Eventos imprevistos**: Problemas de salud, cambios de trabajo, etc.
  - **Errores en la recolección de datos**: Intencionales o no
- La **deserción obliga a los académicos a hacer suposiciones** sobre los datos faltantes
- La principal es que **la ausencia de datos es ignorable**, es decir, no está relacionada con el resultado
- Otro enfoque es suponer que **la ausencia de datos está relacionada con variables observadas**
- En este caso, se pueden utilizar **algunos métodos estadísticos** para modelar el mecanismo de ausencia de datos
- Finalmente, podemos **intentar recolectar más datos** para reducir la **deserción**, pero esto no siempre es factible

# Casos especiales de deserción

# Casos especiales de deserción

## *Datos faltantes independientes de los resultados potenciales*

- ¡La **deserción aleatoria** es el mejor de los casos!
- Esta afirmación generalmente **no se verifica directamente**, sino que se asume
- Formalmente,
$$Y_i(z) \perp R_i(z)$$
- En algunos casos, esto puede ser cierto, como un mal funcionamiento de la computadora que causa la pérdida de datos de algunos participantes
- ¡De hecho, podemos probar eso!
  - Simplemente haga una regresión de  $r_i$  sobre las covariables y la asignación del tratamiento y no debería encontrar una relación significativa
- Si la **deserción** es aleatoria, podemos **ignorarla** y continuar con nuestro análisis
- Sin embargo, todavía tiene problemas:
  - **Poder reducido** debido a un tamaño de muestra más pequeño
  - Problemas de **generalización**
- Pero al menos podemos **estimar el ATE** sin sesgo 🤔
- **¿Cuáles son otros ejemplos de deserción aleatoria?** ¿Se le ocurre alguno?

# Casos especiales de deserción

## *Datos faltantes relacionados con variables observadas*

- Dado que la **deserción aleatoria** es rara, a menudo tenemos que lidiar con **deserción no aleatoria**
- Un tipo especial es la **ausencia independiente de los resultados potenciales dado X**, o **MIPO|X** (missing independent of potential outcomes given X)
  - $Y_i(z) \perp R_i(z) | X_i$
- Puede incluir más covariables en  $X_i$  si cree que están relacionadas con la **deserción**
- Imaginamos que hay una intervención que mejora los resultados de los estudiantes, pero algunos estudiantes no asisten a la escuela el día de la evaluación
- Supongamos que estudiantes con poca asistencia tienen más probabilidades de ausentarse el día de la evaluación y más probabilidades de beneficiarse de una intervención
- **MIPO|X** significa que si uno **divide la muestra experimental por asistencia previa**, la **ausencia es aleatoria dentro de cada subgrupo**
- Entre los estudiantes cuyo historial de asistencia es deficiente, no existe una relación entre la ausencia a la escuela el día de la evaluación y los resultados potenciales de los sujetos
- Lo mismo ocurre con los estudiantes con un buen historial de asistencia



# Ponderación por probabilidad inversa

*Una forma de manejar los datos faltantes relacionados con variables observadas*

- Podemos compensar los datos faltantes **ponderando los datos observados**
- La idea es **sobreponderar las observaciones que son similares a las faltantes**
- Permítanme darles un ejemplo sencillo:
  - Supongamos que tenemos 40 personas en nuestro experimento
  - 30 son hombres y 10 son mujeres
  - El promedio general sería  $\frac{30}{40} \times$  promedio de los hombres +  $\frac{10}{40} \times$  promedio de las mujeres
- Ahora supongamos que 15 de los 30 hombres abandonan
- “Controlando por género” (es decir, ponderando):
  - Los 15 hombres restantes producen una estimación insesgada del promedio entre los 30 hombres
  - ¡Así que podemos **contarlos dos veces!**
  - Esta es la esencia de la **ponderación por probabilidad inversa** (IPW - Inverse Probability Weighting)

# Ponderación por probabilidad inversa

## La fórmula

- IPW estima el ATE cuando se cumple  $MIPO|X$
- Para estimar el ATE, necesitamos  $E[Y_i(1)]$  y  $E[Y_i(0)]$  (¡como ya saben!)
- Cuando se cumple  $MIPO|X$ ,  $E[Y_i(1)]$  es un promedio ponderado:

$$E[Y_i(1)] = \frac{1}{N} \sum_{i=1}^N \frac{Y_i(1)r_i(1)}{\pi_i(z = 1, x)},$$

- $\pi_i(z = 1, x)$ : proporción de sujetos no ausentes entre los tratados con perfil de covariable  $x$
- Los resultados faltantes no tienen efecto en la suma
- Resultados informados ponderados por  $1/\pi_i(z = 1, x)$
- Las ponderaciones reemplazan los valores faltantes con copias de los valores no faltantes
- El esquema de ponderación se llama **ponderación por probabilidad inversa** porque **las observaciones se ponderan por la probabilidad inversa de ser observadas**

# Desventajas de IPW

*Cuando  $MIP O|X$  es incorrecto*


- El supuesto incorrecto de  $MIP O|X$  conduce a estimaciones engañosas
- IPW asigna las mayores ponderaciones a los subgrupos con alta deserción
- La estimación sesgada de un subgrupo puede influir desproporcionadamente en el ATE general
- El promedio de IPW puede estar más sesgado que los datos no ponderados
- La reponderación aumenta la variabilidad del muestreo
- En la práctica, los investigadores deben hacer suposiciones sobre la deserción
- Evaluar  $MIP O|X$ : trabajo de detective y especulación 🕵️
- Más información sobre IPW en [este conjunto de diapositivas](#)

¿Qué podemos hacer? 🤔🧐

# ¿Qué podemos hacer?

## *Un checklist*

- Compruebe si las **tasas de deserción son similares** en los grupos de tratamiento y control.
- Compruebe si las covariables de los grupos de tratamiento y control tienen **padrones similares**.
- **No elimine las observaciones con datos faltantes** en las variables de resultado.
- A veces, cuando faltan datos en la variable de resultados, **podemos acotar ("bound") nuestras estimaciones** del efecto del tratamiento.



# Análisis de cotas extremas

## *Extreme Bounds Analysis (EBA)*

- Imagina los resultados faltantes de aquellos que abandonaron
- No sabemos cuáles son esos resultados, pero podemos considerar dos escenarios extremos:
- Mejor escenario posible: Asumir que los desertores en el grupo de tratamiento habrían tenido los mejores resultados posibles, y los desertores en el grupo de control habrían tenido los peores resultados posibles (en relación con los datos observados)
- Peor escenario posible: Asumir que los desertores en el grupo de tratamiento habrían tenido los peores resultados posibles, y los desertores en el grupo de control habrían tenido los mejores resultados posibles
- Al calcular el ATE bajo estos supuestos extremos, obtenemos un rango (cota superior y cota inferior) que (con suerte 😊) contiene el ATE verdadero

# Un ejemplo sencillo

- Supongamos que nuestro programa tiene los siguientes resultados si no hay deserción:
  - Promedio para el grupo de tratamiento:  $\frac{(7+10+6+6)}{4} = \frac{29}{4} = 7.25$
  - Promedio para el grupo de control:  $\frac{(3+7+5+6)}{4} = \frac{21}{4} = 5.25$
  - ATE:  $7.25 - 5.25 = 2$
- Ahora, supongamos que solo observamos los siguientes resultados:
  - Promedio para el grupo de tratamiento:  $\frac{(7+10+?+?) }{4} = ?$
  - Promedio para el grupo de control:  $\frac{(?+7+5+6)}{4} = ?$
- Asumamos que los resultados recopilados muestran que los valores posibles para los datos faltantes están entre 0 y 10
- ¡Veamos cómo calcular las cotas para el ATE!

# Un ejemplo sencillo

- Para encontrar la **cota superior** de la estimación del efecto del tratamiento, **sustituya 10 por los valores faltantes en el grupo de tratamiento y 0 por el valor faltante en el grupo de control**
- Cota superior:  $\frac{(7+10+10+10)}{4} - \frac{(0+7+5+6)}{4} = \frac{37}{4} - \frac{18}{4} = 4.75$
- Para encontrar la cota inferior de la estimación del efecto del tratamiento, **sustituya 0 por los valores faltantes en el grupo de tratamiento y 10 por el valor faltante en el grupo de control**
- Cota inferior:  $\frac{(7+10+0+0)}{4} - \frac{(10+7+5+6)}{4} = \frac{17}{4} - \frac{28}{4} = -2.75$
- Entonces, el **ATE está entre -2.75 y 4.75...** ¡y de hecho lo es (2)! 🎉
- Pero como puedes ver, **las cotas son bastante amplias...**
- [Lee \(2009\)](#) sugirió que podemos **recortar las cotas** para hacerlas más informativas (y más estrechas)
- Más información sobre el análisis de cotas extremas en [este conjunto de diapositivas](#)




# ¿Qué podemos hacer?

- Pero la mejor solución es tratar de anticipar y prevenir la deserción.
- Personas que **no sepan a qué condición** del tratamiento fueron asignadas.
- Prometerle al grupo de control que **va a recibir el tratamiento** na vez concluida la investigación.
- **Planificar ex ante** para poder contactar a los sujetos en para la recolección final de datos.
- Contar con presupuesto para haver **seguimiento intensivo** a una muestra aleatoria de los sujetos que desierten



# Los datos faltantes en covariables de contexto no son tan problemáticos

- La ausencia de datos en **covariables de contexto** (es decir, variables cuyos valores no cambian como resultado del tratamiento) para algunas observaciones **es menos problemática**.
- Podemos aprender sobre el efecto causal de un experimento incluso sin esas covariables
- Podemos usar la covariable de contexto según lo planeado **imputando los datos faltantes**
- También podemos condicionar nuestro análisis directamente a esos datos faltantes



# Incumplimiento

# Incumplimiento

## *Incumplimiento*

- En algunas ocasiones **las unidades que son asignadas al tratamiento terminan no recibéndolo**. Es decir, no cumplen la asignación.
- Si todas las unidades asignadas al grupo de control no toman el tratamiento, pero sólo algunas unidades asignadas al tratamiento sí lo toman, estamos frente a un caso de incumplimiento unilateral.
- El efecto de ser asignado al tratamiento no es el mismo que el de recibir el tratamiento.
- El efecto de recibir el tratamiento es comunmente conocido como “efecto local promedio del tratamiento” (**LATE**) o efecto promedio del tratamiento para el cumplidor (**CACE**).
- La palabra “local” hace referencia a la idea de que el efecto solo aplica para las personas que toman el tratamiento cuando son asignadas a éste (el tipo de personas).

# Un ejemplo motivador

## *Campaña para aumentar la participación electoral*

- Imagina que estás interesado en estudiar el efecto de las campañas electorales en la participación de los votantes
  - ¡Quizás si tocas las puertas de las personas y les hablas sobre la importancia de votar, serán más propensas a hacerlo!
- Diseñas un experimento en el que asignas aleatoriamente a 1000 personas para que reciban la campaña (grupo de tratamiento) y a 1000 para que no la reciban (grupo de control)
- Sin embargo... usualmente solo el 25% de las personas en el grupo de tratamiento reciben realmente la campaña
  - El resto no está en casa, se niega a hablar, etc.
- Así que tenemos 250 personas tratadas y 1000 en el grupo de control
- ¿Qué harías? 🤔

# Algunas opciones

- La primera opción que tenemos es simplemente **comparar los dos grupos** como si nada hubiera pasado
- El problema con este enfoque es que podría haber un **sesgo de selección** en el grupo de tratamiento
- La segunda opción, relacionada con la primera, es **asumir que las diferencias entre los dos grupos son aleatorias**
- El problema con este enfoque es que **no podemos probar esa suposición**
- No podemos saber si las diferencias entre los dos grupos son aleatorias o no
- ¡Lo más probable es que no lo sean!
- La tercera opción es **mantener la asignación aleatoria** y comparar los dos grupos como si todos hubieran seguido la asignación del tratamiento
- En lugar de comparar a las personas que realmente recibieron la campaña con las que no la recibieron, **comparamos a las personas que fueron asignadas a recibir la campaña con las que no fueron asignadas a recibirla**
- La diferencia aquí es **semántica**:
  - Podríamos recuperar el ATE verdadero si solo le hubiéramos dado a la gente la opción de recibir o no la campaña
- La cuarta opción es usar **variables instrumentales (VI)** (o mínimos cuadrados en dos etapas - 2SLS)
- El beneficio de las VI es que nos permite **recuperar el efecto real del programa** en lugar de solo el efecto de que se ofrezca el programa
- La desventaja es que **las VI no nos permiten recuperar el ATE verdadero** en toda la población, solo en la subpoblación de cumplidores

CACE y VI 🧐

# Efecto causal promedio del cumplidor (CACE)

## *El efecto del tratamiento en los cumplidores*

- Como no podemos estimar correctamente el ATE con incumplimiento, nos centramos en el **efecto causal promedio del cumplidor (CACE)**
- El CACE intenta responder a esta pregunta: “**Para aquellos individuos que realmente escucharon el mensaje, ¿cuál es el efecto del mensaje en su probabilidad de votar?**”
- Sea la asignación experimental del sujeto  $i$ ,  $z_i$ .
- Cuando  $z_i = 1$ , el sujeto es asignado al grupo de tratamiento, y cuando  $z_i = 0$ , el sujeto es asignado al grupo de control.
- Sea  $d_i(z)$  una representación de si el sujeto  $i$  es realmente tratado, dada la asignación  $z_i$ .
- Para abreviar, escribamos  $d_i(z = 1)$  como  $d_i(1)$  y  $d_i(z = 0)$  como  $d_i(0)$ .
- Para el incumplimiento unilateral,  $d_i(0)$  es siempre 0 para todas las personas en los grupos de control, pero  $d_i(1)$  puede ser 0 o 1.
- Formalmente, el CACE se define como:

$$CACE \equiv \frac{\sum_{i=1}^N (Y_i(1) - Y_i(0))d_i(1)}{\sum_{i=1}^N d_i(1)} = E[(Y_i(d = 1) - Y_i(d = 0)) | d_i(1) = 1]$$


- En otras palabras, es **el efecto del tratamiento, pero solo proveniente de los cumplidores, dividido por el número de cumplidores**
- El CACE también se conoce como **Efectos Locales Promedio del Tratamiento (LATE)**. [Más en este link.](#)



# CACE y variables instrumentales

## *El efecto del tratamiento en los cumplidores*

- Lo bueno del CACE/LATE es que tenemos un estimador consistente para él
- Equivalente a los **estimadores de mínimos cuadrados en dos etapas**
  - Regresar  $D_i$  sobre  $Z_i$  para obtener los valores ajustados  $\hat{D}_i$
  - Regresar  $Y_i$  sobre  $\hat{D}_i$
- Pero recuerde los supuestos:
  - La **no interferencia** se violará, por ejemplo, si el sujeto  $j$  es contactado y se lo cuenta a  $i$
  - La **excluibilidad** también puede violarse si los controles son tratados por otra campaña de contacto
  - La **primera etapa** requiere que al menos una persona sea tratada



Fuente: Blackwell (2021)

# Estimando las regresiones

- Volvamos a nuestro ejemplo de campaña electoral
- Tenemos las siguientes regresiones para estimar el CACE:
  - Primera etapa:  $TRATADO_i = \alpha_0 + \alpha_1 ASIGNADO + \epsilon_i$
  - Segunda etapa:  $VOTÓ_i = \beta_0 + \beta_1 TRATADO + u_i$
- La primera etapa estima el efecto de la asignación del tratamiento sobre el estado del tratamiento
- La segunda etapa estima el efecto del estado del tratamiento sobre el resultado
- El coeficiente  $\beta_1$  es el estimador de **mínimos cuadrados en dos etapas (MC2E)** del CACE
- Más información sobre el CACE y las variables instrumentales en [este link](#)

# Derrame

# Derrame e interferencia entre unidades

## *Derrame e interferencia entre unidades*

- A veces tendremos sospechas de que la asignación al tratamiento de una unidad **afecta los resultados de otras unidades**.
- Si el tratamiento de una unidad afecta el resultado de otra unidad, estamos **violando uno de los supuestos básicos de inferencia causal**.
- Podemos seleccionar unidades que están **lejos unas de otras** para evitar la “transmisión” del tratamiento entre unidades.




# ¡No todos los derrames son malos!

- Como hemos visto, muchos fenómenos sociales son **interdependientes**
- Pero algunos están explícitamente **diseñados para aprovechar los derrames**
  - **Contaminación**: El efecto de vacunarse en la probabilidad de contraer una enfermedad depende de si otros están vacunados
  - **Efectos de red**: El valor de un producto o servicio aumenta a medida que más personas lo usan (redes sociales, telecomunicaciones)
  - **Vigilancia en puntos calientes**: El efecto de una mayor presencia policial en un área puede reducir el crimen en áreas cercanas
  - **Disuasión**: El efecto de un castigo más severo en un individuo puede disuadir a otros de cometer delitos

## Hot spots policing in a high-crime environment: an experimental evaluation in Medellín



Daniela Collazos<sup>1</sup> · Eduardo García<sup>2</sup> · Daniel Mejía<sup>3</sup> · Daniel Ortega<sup>4</sup> · Santiago Tobón<sup>5</sup> 

Published online: 13 February 2020  
© Springer Nature B.V. 2020

### Abstract

**Objectives** Test direct, spillover, and aggregate effects of hot spots policing on crime in a high-crime environment.

**Methods** We identified 967 hot spot street segments and randomly assigned 384 to a six-month increase in police patrols. To account for the complications resulting from a large experimental sample in a dense network of streets, we use randomization inference for hypothesis testing. We also use non-experimental streets to test for spillovers onto non-hot spots and examine aggregate effects citywide.

**Results** Our results show an improvement in short-term security perceptions and a reduction in car thefts, but no direct effects on other crimes or satisfaction with policing services. We see larger effects in the least secure places, especially for short-term security perceptions, car thefts, and assaults. **We find no evidence of crime displacement but rather a decrease in car thefts in nearby hot spots and a decrease in assaults in nearby non-hot spots.** We estimate that car thefts decreased citywide by about 11%.

Fuente: Collazos et al. (2021)

# Estudiar los efectos secundarios

- Esto no es un problema si diseñas un estudio que permita investigar el derrame, es decir, que los resultados de una unidad pueden depender del tratamiento de otras unidades.
- Para investigar los efectos de derrame:
- Podemos recolectar datos de la variable de resultado para las unidades que nunca fueron elegibles para la asignación aleatoria al tratamiento, pero que estaban cerca de unidades que sí eran elegibles para el tratamiento y que pudieron verse afectadas por efectos de derrame.
- Podemos utilizar un diseño de asignación aleatoria en dos etapas.
- Podemos asignar grupos de unidades (p. Ej., Distritos) a diferentes niveles de intensidad de tratamiento (p. Ej., Usar una proporción diferente de aldeas en los distritos asignados al tratamiento).

# Un ejemplo

## *Campaña para aumentar la participación electoral*

- Imagina que estamos realizando un experimento para probar el efecto de una campaña para salir a votar en la participación electoral
- Tenemos un **diseño multinivel**:
  - Los **hogares** se asignan aleatoriamente a tratamiento o control
  - Dentro de los hogares, los **individuos** también se asignan aleatoriamente
- Nos centramos en **hogares de dos votantes** donde los residentes comparten dirección
- Grupos de asignación aleatoria:
  - 5,000 hogares: ambos votantes objetivo
  - 5,000 hogares: ninguno objetivo
  - 10,000 hogares: uno aleatoriamente objetivo
- Crea cuatro grupos de 10,000 personas:
  - **Correo recibido por ambos**
  - **Ninguno recibe correo**
  - **Correo con compañero de casa no tratado**
  - **No tratado con compañero de casa tratado**
- Características del **diseño multinivel**:
  - **Aleatorización en dos etapas** (hogar y luego individuo)
  - Ampliable a **niveles adicionales como código postal**

# Un ejemplo

## *Campaña para aumentar la participación electoral*

- Los resultados potenciales dependen tanto del estado de tratamiento propio como del compañero de casa
- El sistema de notación revisado tiene en cuenta las influencias de tratamiento dual ( $Y_{ab}$  donde):
  - $a$  = estado de tratamiento del compañero de casa (0=control, 1=tratado)
  - $b$  = estado de tratamiento propio (0=control, 1=tratado)

| Notación | Compañero de casa | Propio  | Interpretación                 |
|----------|-------------------|---------|--------------------------------|
| $Y_{00}$ | Control           | Control | Resultado base                 |
| $Y_{01}$ | Control           | Tratado | Efecto directo del tratamiento |
| $Y_{10}$ | Tratado           | Control | Efecto de derrame              |
| $Y_{11}$ | Tratado           | Tratado | Efectos combinados             |

- Supuesto clave: Contención estricta en el hogar
  - Resultados solo afectados por intervenciones dentro del hogar
  - Sin interferencia de asignaciones de tratamiento externas



# Definiendo los efectos causales

- De los **cuatro resultados potenciales**, surgen estimandos clave:
  - $Y_{01} - Y_{00}$ : **Efecto directo** del tratamiento cuando el compañero de casa no es tratado
  - $Y_{11} - Y_{10}$ : **Efecto del tratamiento** cuando el compañero de casa recibe correo
  - $Y_{10} - Y_{00}$ : **Efecto de derrame** en no tratados con compañero de casa tratado
  - $Y_{11} - Y_{01}$ : **Interacción de derrame** entre pares tratados
- Consideraciones críticas:
  - Los efectos dependen del **estado de tratamiento del compañero de casa**
  - Los estimandos capturan **influencias combinadas** de:
    - ⇒ Impactos directos de la intervención
    - ⇒ Derrames por comunicación
    - ⇒ Efectos de recursos compartidos
  - No aísla **mecanismos** específicos detrás de los derrames

# Desafíos de implementación

## *Consideraciones prácticas*

- Obstáculos comunes de implementación:
  - Contaminación del tratamiento entre grupos
  - Deserción diferencial entre condiciones
  - Complejidades del monitoreo del cumplimiento
  - Asignación de recursos para seguimiento multinivel
- Consideraciones éticas:
  - Consentimiento informado para miembros de la red
  - Protección de la privacidad para datos del hogar
  - Implicaciones de equidad de los efectos de derrame
- Limitaciones de diseño a abordar:
  - Requisitos de tamaño de muestra para efectos de clúster
  - Desafíos de medición para impactos indirectos
  - Aspectos temporales del momento del derrame
  - Estimación correcta de errores estándar, ya que los sujetos probablemente están correlacionados de muchas maneras

**Nota:** El pre-registro es crucial para diseños complejos

# Efecto Hawthorne 🧐📷

# Efecto Hawthorne 🙇

- El efecto Hawthorne: **saber que están siendo observados/estudiados** puede llevar a los sujetos a comportarse de manera diferente.
- Esto podría crear un **error de medición sistemático** tanto en los grupos de tratamiento como en los de control.
- También podría resultar de una **mayor atención prestada al grupo de tratamiento**, deshaciendo la creación de grupos de tratamiento y control equivalentes creados a través de la asignación aleatoria



# Buenas practicas

- Recolectar datos de la forma más discreta posible.
- En la medida de lo posible, nadie más que el propio sujeto debe conocer a qué condición de tratamiento fue asignado.
- Encuestadores/investigadores deberían desconocer la condición de tratamiento de los sujetos.
- No debemos hacer mediciones adicionales para el grupo de tratamiento.

# No excluibilidad

# Diferencias entre los grupos de tratamiento y control más allá del tratamiento

- Manejar los grupos de tratamiento y control de manera diferente significa que las diferencias observadas en las variables de resultado entre estos grupos pueden deberse al tratamiento y/o al manejo diferente.
- Los ejemplos incluyen el uso de diferentes cuestionarios para la recolección de datos o rondas adicionales de recolección de datos para el grupo de tratamiento con la intención de obtener información sobre los mecanismos.
- Recuerde diseñar su estudio y sus encuesta para tratar todos los brazos de tratamiento por igual, excepto por el tratamiento en sí.

